



EED2

Estadística y Exploración de Datos

Carrera en

Inteligencia Artificial y Ciencia de datos

Autores

Abril Reyna

Muestreo




Índice

01
02

Decisiones referidas al muestreo 6

Representatividad 8

Metas de comprensión



1.02

Muestreo

a

Evidenciar el uso del muestreo en la era del big data.

b

Recorrer las etapas de la encuesta: decisiones previas, propias y posteriores al muestreo.

c

Recuperar la noción de representatividad.

Introducción a la clase


En el proceso de tomar decisiones –tanto en el quehacer diario de las personas como de las empresas- se requiere disponer de la mayor información posible sobre el tema en cuestión. Generalmente, la información que se requiere está referida a un universo de unidades de análisis que tiene un tamaño muy grande (N). Si se desea hacer un relevamiento total, completo y exhaustivo de dicha población (Censo) se ha de insumir mucho tiempo y recursos.

Para resolver estos problemas prácticos surgió la teoría del muestreo, que es un capítulo de la estadística y de la teoría aplicada de las probabilidades. Esta teoría trata sobre los fundamentos probabilísticos, las distribuciones estadísticas, los métodos o técnicas de selección, las fórmulas de cálculo de los errores de muestreo, las fórmulas y tablas de determinación del tamaño de la muestra, los métodos de estimación de los parámetros poblacionales a partir de los estadísticos muestrales.

Veremos una guía clásica de introducción a la teoría de las muestras. Esta teoría indica los procedimientos o técnicas para extraer una parte o muestra del colectivo o población que se quiere estudiar, o analizar en ella las características que interesen y el del resultado de este análisis inferir o afirmar algo del universo total.

Un error muy extendido sostiene que la era de los macrodatos (big data) va a suponer el fin de la necesidad de hacer muestreos. De hecho, la proliferación de datos de diferente calidad y relevancia **refuerza la necesidad del muestreo** como herramienta para trabajar de manera eficiente con una serie de datos y minimizar el sesgo. Incluso en un proyecto de big data, los modelos predictivos generalmente se desarrollan y se ponen a prueba mediante muestras.





El ejemplo clásico es la encuesta del Literary Digest de 1936 que predijo una victoria de Alf Landon sobre Franklin Roosevelt. El **Literary Digest**, uno de los principales diarios, encuestó a sus suscriptores además de hacerlo a los individuos que figuraban en otras listas, llegando a un total de más de 10 millones de personas, y predijo una victoria aplastante de Landon. **George Gallup**, fundador de Gallup Poll, realizó encuestas quincenales a solo 2000 personas y predijo acertadamente una victoria de Roosevelt. **La diferencia radica en la selección de los encuestados.** Literary Digest apostó por la cantidad, prestando poca atención al método de selección. Terminaron encuestando a personas con un estatus socioeconómico relativamente alto (sus propios suscriptores, más aquellos que, en virtud de poseer lo que se consideraban lujos como eran los teléfonos y automóviles, aparecían en las listas de los especialistas en marketing). El resultado fue el sesgo de la muestra, es decir, **la muestra era, de manera significativa y no aleatoria**, diferente de la población más grande a la que se pretendía representar. Para evitar el problema del sesgo de la muestra que llevó al Literary Digest a pronosticar la victoria de Landon sobre Roosevelt, George Gallup optó por elegir un método con una base más científica para lograr una muestra que fuera representativa del electorado votante de EE. UU. Y obtuvo acertadamente una respuesta. Roosevelt ganaría.

01. Decisiones referidas al muestreo

Se ha producido una variada nomenclatura para establecer las etapas a considerar en la ejecución de la encuesta para establecer las etapas a considerar por muestreo. El diseño de una encuesta por muestreo implica tomar decisiones en tres momentos. En efecto cabe distinguir decisiones previas al muestreo, propias del muestreo y decisiones posteriores a la selección de la muestra.

Decisiones previas al muestreo

Antes de iniciar un proceso de muestreo, es crucial tomar varias decisiones clave para asegurar que la investigación sea precisa y válida. Estas decisiones incluyen los siguientes aspectos:

1. Definición del objeto de estudio:

- Se debe establecer claramente el **tema** o **fenómeno** que se va a investigar. Esto incluye definir con precisión los objetivos de la investigación.

2. Variabilizar:

- Se debe **definir operativamente** las variables de interés, lo que significa que cada concepto debe ser transformado en algo medible y específico. Esto incluye la creación de definiciones operacionales claras para que las variables sean precisas y comprensibles.

3. Definir la población:

- Es importante establecer cuál será la **población** de la que se desea hacer inferencias. Esto implica definir los **elementos** o **unidades** que componen esa población, es decir, quiénes o qué serán considerados dentro de la muestra.

4. Establecer el marco muestral:

- Se debe tener un **marco muestral** que contenga toda la información necesaria para identificar y seleccionar las unidades de la población que serán incluidas en el muestreo. Este marco es esencial para asegurar que la muestra sea representativa.

5. Diseñar el instrumento de medición:

- Es necesario crear o seleccionar un **instrumento de medición** adecuado para la recolección de datos. Esto puede incluir encuestas, cuestionarios o entrevistas, y debe estar alineado con las variables definidas previamente. También se deben especificar los **índices** y **escalas** a utilizar, dependiendo de la naturaleza de las variables.

6. Selección del método de recolección de datos:

- Se deben definir las **técnicas de recolección** de información, que pueden ser personales (entrevistas cara a cara), postales, telefónicas o incluso por medios electrónicos como encuestas en línea. La elección depende de los recursos disponibles y de la población objetivo.

7. Formulación del cuestionario:

- Se debe diseñar un **cuestionario** que contenga las preguntas necesarias para recopilar los datos. Las preguntas deben estar redactadas de manera clara y ser coherentes con los objetivos de la investigación. La estructura puede variar según el formato (abiertas, cerradas, de escala, etc.).

8. Entrenamiento de encuestadores:

- Si se utiliza personal para aplicar las encuestas, es fundamental **entrenar a los encuestadores**. Esto asegura que las entrevistas se realicen de manera uniforme y que los datos recogidos sean consistentes. El entrenamiento debe incluir instrucciones sobre el uso del instrumento de medición y cómo abordar a los encuestados.

9. Encuesta piloto:

- Antes de aplicar la encuesta a toda la muestra, es recomendable realizar una **encuesta piloto**. Esto implica probar el instrumento de medición en un grupo pequeño de personas para evaluar su efectividad. En esta etapa se pueden detectar posibles problemas, como preguntas confusas o dificultades en la recolección de datos.

Decisiones propias del muestreo

1. **Selección del tipo de muestreo:** Elegir entre las opciones de muestreo probabilístico y no probabilístico.
2. **Determinación del tamaño de la muestra:** Aplicar la formula correspondiente según el procedimiento de selección de muestreo elegido.
3. **Nivel de confianza y probabilidad de error:**
 - Se deben tomar decisiones sobre el nivel de confianza (por ejemplo, 95% o 99%) que se desea alcanzar en las estimaciones. Esto implica decidir la probabilidad de error o el margen de error que se está dispuesto a aceptar. Es decir la precisión de los estimadores.

4. Probabilidad de selección de las unidades de muestreo:

- En este punto, se establece si todas las unidades de la población tendrán la misma probabilidad de ser seleccionadas o si tendrán probabilidades distintas de selección. Por ejemplo, en un muestreo estratificado, algunas unidades pueden tener una probabilidad mayor de ser seleccionadas debido a su pertenencia a un estrato específico.

Decisiones posteriores al muestreo

El momento posterior al muestreo contempla materias del siguiente orden.

1. Codificación y digitalización:

- Principalmente cerrar preguntas abiertas y generar una base de datos.

2. Depuración de la base de datos:

- Evaluar la calidad de los datos pesquizando errores de rango y consistencia.

3. Tratamiento de no respuesta:

- Se trata de identificar los tipos de no respuesta y aplicar los procedimientos de corrección correspondientes.

4. Ponderación y elevación:

- Se pondera asignando pesos diferentes a las unidades muestrales a fin de que no haya elementos subrepresentados o sobrerrepresentados y se eleva multiplicando las unidades muestrales por un coeficiente para obtener desde la muestra los valores que corresponderían a la población origen de la muestra.

02. Representatividad


La **representatividad** es una propiedad clave de una muestra, ya que permite que reproduzca a escala los atributos de la población de la que se extrae. Esto facilita realizar inferencias sobre la población a partir de la muestra. No existe una definición exacta de cuándo una muestra es representativa, pero generalmente se considera representativa cuando reproduce la distribución de frecuencias de ciertas **variables marcadoras** (como las sociodemográficas).

El **azar** no garantiza que una muestra seleccionada aleatoriamente sea representativa, pero es fundamental en la **inferencia estadística**. A medida que se seleccionan más elementos de manera aleatoria e independiente, los sesgos se reducen, lo que aumenta la probabilidad de que la muestra sea representativa. Aunque el azar no asegura representatividad, ofrece una esperanza razonable de que la muestra refleje a la población.

Cierre de la clase

¡Nos vemos la próxima clase!

¡Hasta la clase 3!



Créditos

Tipografía

Para este diseño se utilizó la tipografía Source Sans Pro diseñada por Paul D. Hunt. y Space Mono diseñada por Colophon Foundry Extraída de Google Fonts.

Errores y correcciones

Si detectás un error del tipo que fuere (falta un punto, un acento, una palabra mal escrita, un error en código, etc.), por favor comunicate con nosotros a

correcciones@issd.edu.ar

e indicanos por cada error que detectes la página y el párrafo.
Muchas gracias por tu aporte.