



EED2

**Estadística y Exploración
de Datos**

Carrera en

Inteligencia Artificial y Ciencia de datos

Autores

Abril Reyna

Contraste de hipótesis

02 | 06

UNIDAD


CLASE

Índice

01
02

¿Qué es?	5
Bootstrapping	6

Metas de compresión



2.06

Contraste de hipótesis

a

Superar las Limitaciones de los Métodos Paramétricos.

b

Desarrollar habilidades computacionales referidas al análisis de datos.

c

Obtener resultados más precisos.

Introducción

Imagina que una farmacéutica ha desarrollado un nuevo medicamento para reducir el colesterol. Quieren evaluar si este medicamento es realmente efectivo en comparación con un placebo (una sustancia sin efecto terapéutico). No es viable hacer la prueba en todos los seres humanos así que trabajaremos con una muestra para hacer una inferencia sobre la población. Realizaremos esa inferencia mediante dos técnicas: intervalos de confianza y p-valor.

01. ¿Qué es?

Es un método que permite decidir si una hipótesis previamente emitida sobre un parámetro desconocido se acepta o se rechaza con una probabilidad fijada con anterioridad α (NS) Hipótesis Distinguiremos dos tipos:

- Hipótesis nula (H_0): Es lo que se da por verdadero antes de realizar el contraste.
- Hipótesis alternativa (H_1): Es lo que queremos demostrar luego de realizar el contraste.

Deben cumplir:

- Ser mutuamente excluyentes.
- Ser mutuamente complementarias.

Simbología:

- $= \leq \geq$
- $\neq < >$

En el ejemplo:

Hipótesis nula (H_0): El nuevo medicamento no tiene ningún efecto en la reducción del colesterol, es decir, es igual de efectivo que el placebo.

Hipótesis alternativa (H_1): El nuevo medicamento sí reduce el colesterol en comparación con el placebo.


Si el medicamento no tiene efecto sobre la reducción del colesterol entonces no puede tener efecto por lo que son excluyentes entre si las hipótesis.

El medicamento puede funcionar o no puede funcionar, no hay una tercera opción por lo que son complementarias las hipótesis.

Nota: Suele llamarse A/B Test o A/B testing. Si se busca la veracidad de la hipótesis alternativa entonces simbolizamos $H_1 > H_0$

02. Bootstrapping

Supongamos que tenemos una muestra de 7 personas que se sometieron a los efectos del medicamento. Se les realiza la pregunta ¿Cuál fue el efecto del medicamento en su organismo?




Se calcula la media del conjunto (marcada con línea roja)

El bootstrap es un método de remuestreo no paramétrico que se utiliza en estadística para estimar diversas cantidades, como la media, la desviación estándar, intervalos de confianza y distribuciones de muestreo.

Su principal ventaja radica en que no requiere asumir una distribución particular para los datos, lo que lo hace muy versátil.

¿Cómo funciona?

1. Muestreo con reemplazo: A partir de un conjunto de datos original, se extraen repetidamente muestras del mismo tamaño, pero permitiendo que los elementos se repitan. Es decir, en cada muestra, un mismo dato puede aparecer varias veces o ninguna.
2. Cálculo del estadístico: Para cada muestra obtenida, se calcula el estadístico de interés (por ejemplo, la media).
3. Distribución de muestreo empírica: Al repetir este proceso muchas veces (miles o decenas de miles), se obtiene una distribución de muestreo empírica del estadístico. Esta distribución nos proporciona información sobre la variabilidad del estadístico y permite construir intervalos de confianza




El bootstrapping vino a reemplazar algunas técnicas estadísticas tradicionales (intervalos de confianza y p-valor) para simplificar los supuestos, lo único que debemos tener en cuenta es que la muestra que tomemos debe ser representativa de la población. Seguiremos con el tratamiento del problema inicial. Adjunto tendrán un archivo csv que recopila la información de la puntuación que le dieron los voluntarios a la medicación suministrada con valores del -10 al 10.

Se crea una lista vacía llamada `boot_medias`. Esta lista servirá para almacenar las medias calculadas en cada iteración del bucle. Se inicia un bucle `for` que se ejecutará 10,000 veces. Cada iteración representará una nueva muestra bootstrap.

En cada iteración: Se selecciona una muestra aleatoria de 150 bservaciones del DataFrame original (`df_muestra`). El argumento `replace=True` indica que se permite la selección repetida de observaciones dentro de una misma muestra. Se calcula la media de la columna 'Puntuacion' de la muestra bootstrap creada y se agrega a la lista `boot_medias`. Crea un histograma de la lista `boot_medias`, que contiene las medias calculadas en cada iteración del bootstrap. El punto y coma al final de la línea suprime la salida de texto por defecto de `matplotlib`.

```
df=pd.read_csv('puntuaciones.csv', sep=';')
df_muestra=df[:150]
DF_muestra.hist()
```

Realizamos la lectura del archivo. Tomamos una muestra de 150 elementos y ejecutamos histogramas para ver la distribucúón de la muestra.



Vemos que la distribución no creaun patrón determinado o conocido.

```
# crear el bootstrapping
boot_medias=[]
for i in range(10000):
    boot_datos= df_muestra.sample(150,replace= True)
    boot_medias.append(boot_datos['Puntuacion'].mean())
```

Se crea una lista vacía llamada `boot_medias`. Esta lista servirá para almacenar las medias calculadas en cada iteración del bucle. Se inicia un bucle `for` que se ejecutará 10,000 veces. Cada iteración representará una nueva muestra bootstrap. • En cada iteración: Se selecciona una muestra aleatoria de 150 bservaciones del DataFrame original (`df_muestra`). El argumento `replace=True` indica que se permite la selección repetida de observaciones dentro de una misma muestra. Se calcula la media de la columna 'Puntuacion' de la muestra bootstrap creada y se agrega a la lista `boot_medias`. Crea un histograma de la lista `boot_medias`, que contiene las medias calculadas en cada iteración del bootstrap. El punto y coma al final de la línea suprime la salida de texto por defecto de `matplotlib`

```

import matplotlib.pyplot as plt
plt.hist(boot_medias);
import numpy as np
import matplotlib.pyplot as plt
from ipywidgets import interact, FloatSlider

nivel_confianza = 0.97
percentil_inferior = (1 - nivel_confianza) / 2
percentil_superior = 1 - percentil_inferior
limite_inferior = np.percentile(boot_medias, percentil_inferior *
100)
limite_superior = np.percentile(boot_medias, percentil_superior *
100)

def plot_confidence_interval(nivel_confianza):
    percentil_inferior = (1 - nivel_confianza) / 2
    percentil_superior = 1 - percentil_inferior
    limite_inferior = np.percentile(boot_medias, percentil_
inferior * 100)
    limite_superior = np.percentile(boot_medias, percentil_
superior * 100)

```

Calcular el intervalo de confianza del 97%

Crear la función para el gráfico interactivo.

Crear el slider interactivo.

```

plt.figure(figsize=(8, 6))
plt.hist(boot_medias, bins=30, density=True,
        alpha=0.6, color='skyblue')
plt.axline(limite_inferior, color='red',
        linestyle='dashed', linewidth=2, label=f'Límite inferior
({nivel_confianza*100:.1f}%)')
plt.axline(limite_superior, color='red',
        linestyle='dashed', linewidth=2, label=f'Límite
superior ({nivel_confianza*100:.1f}%)')
plt.xlabel('Media de la puntuación')
plt.ylabel('Densidad')
plt.title(f'Intervalo de confianza del {nivel_confianza*100:.1f}%
para la media de la puntuación')
plt.legend()
plt.show()


# Crear el slider interactivo
interact(plot_confidence_interval,
        nivel_confianza=FloatSlider(value=0.97,
                                     min=0.5, max=0.99, step=0.01,
                                     description='Nivel de
confianza:'))

print(f"Intervalo de confianza del 97%: [{limite_inferior:.2f},
{limite_superior:.2f}]")

```


Intervalo de confianza del 97.0% para la media de la puntuación

-- -- Límite inferior (97,0%)
-- -- Límite superior (97,0%)



Obtenemos este gráfico donde podemos variar el nivel de confianza del problema y el intervalo de confianza.

Desempeño


Propone una base de datos que te ayude a resolver el siguiente problema:

Una empresa de comercio electrónico desea aumentar la tasa de conversión de sus visitantes en compradores. Actualmente, utilizan un botón de "Agregar al carrito" de color naranja. Se plantea la hipótesis de que cambiar el color del botón a azul podría generar un mayor impacto visual y, en consecuencia, incrementar las conversiones. Determinar si el cambio de color del botón de "Agregar al carrito" de naranja a azul resulta en un aumento estadísticamente significativo en la tasa de conversión, con un nivel de confianza del 95%.

Cierre de la clase

¡Nos vemos la próxima clase!

¡Hasta la clase 7!



Créditos

Tipografía

Para este diseño se utilizó la tipografía Source Sans Pro diseñada por Paul D. Hunt. y Space Mono diseñada por Colophon Foundry Extraída de Google Fonts.

Errores y correcciones

Si detectás un error del tipo que fuere (falta un punto, un acento, una palabra mal escrita, un error en código, etc.), por favor comunicate con nosotros a

correcciones@issd.edu.ar

e indicanos por cada error que detectes la página y el párrafo.
Muchas gracias por tu aporte.